

Denoising Diffusion Probabilistic Models

韩成瑞

东南大学数学学院

2025 年 12 月 10 日



目录

- 1 绪论
- 2 研究内容

目录

- 1 绪论
- 2 研究内容

Denoising Diffusion Probabilistic Models

Jonathan Ho
UC Berkeley
jonathanho@berkeley.edu

Ajay Jain
UC Berkeley
ajayj@berkeley.edu

Pieter Abbeel
UC Berkeley
pabbeel@cs.berkeley.edu

Abstract

We present high quality image synthesis results using diffusion probabilistic models, a class of latent variable models inspired by considerations from nonequilibrium thermodynamics. Our best results are obtained by training on a weighted variational bound designed according to a novel connection between diffusion probabilistic models and denoising score matching with Langevin dynamics, and our models naturally admit a progressive lossy decompression scheme that can be interpreted as a generalization of autoregressive decoding. On the unconditional CIFAR10 dataset, we obtain an Inception score of 9.46 and a state-of-the-art FID score of 3.17. On 256x256 LSUN, we obtain sample quality similar to ProgressiveGAN. Our implementation is available at <https://github.com/hojonathanho/diffusion>.

Denoising diffusion probabilistic models

AUTHORS  Jonathan Ho  Ajay Jain  Pieter Abbeel | [Authors Info & Claims](#)

NIPS'20: Proceedings of the 34th International Conference on Neural Information Processing Systems
Article No.: 574, Pages 6840 - 6851

Published: 06 December 2020 [Publication History](#)

Ajay Jain

[Twitter](#) | [Google Scholar](#) | [GitHub](#) | [LinkedIn](#) | [CV](#) | [Fun things I made](#) | [Older projects](#)



Synthesizing visual worlds

I'm an AI researcher at UC Berkeley, where I work on generative models. My work includes diffusion models, text-to-3D with NeRFs, and scalable ML systems.

Previously, I was at Google Brain, NVIDIA Research, Uber ATG, and Facebook AI. I graduated from MIT with an S.B. in Computer Science and was a director of the nonprofit Machine Intelligence Community. At MIT, I did research at CSAIL and the Media Lab. My research is supported by the NSF Graduate Research Fellowship.



✕ Follow @pabbeel

Contact

Brief bio

Home

Current Positions:

Professor, Jim Gray Chair of Engineering, [UC Berkeley](#)

Director of the [Berkeley Robot Learning Lab](#)

Co-Director of the Berkeley Artificial Intelligence Research ([BAIR](#)) lab

Amazon Scholar (2024–)

Co-Founder, President, and Chief Scientist [Covariant](#) (2017–2024)

Co-Founder [Gradescope](#) (2014–2018: [Acquired by TurnItIn](#))


Host of [The Robot Brains Podcast](#)

Founding Investment Partner at [AIX Ventures](#)

目录

1 绪论

2 研究内容




引言

扩散模型的两个核心过程：

- 前向过程 (Forward/Diffusion Process)：逐步向数据添加噪声
- 反向过程 (Reverse Process)：学习从噪声中恢复数据

关键特点：

- 两个过程均为参数化的**马尔可夫链**
- 反向过程用于**生成新数据**
- 通过**变分推断**进行建模与优化



扩散过程 - 拆楼

核心思想：对数据逐步添加**高斯噪声**，直至变为纯随机噪声（破坏数据）

单步扩散：给定 $\mathbf{x}_0 \sim q(\mathbf{x}_0)$ ，每一步向 $\mathbf{x}_{t-1}$ 添加高斯噪声

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I})$$

完整链式过程： T 步扩散构成前向**马尔可夫链**

$$q(\mathbf{x}_{1:T} | \mathbf{x}_0) = \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1})$$

其中 $\{\beta_t\}_{t=1}^T$ 称为噪声调度 (noise schedule)，满足

$0 < \beta_1 < \beta_2 < \dots < \beta_T < 1$ 。

关键性质：定义 $\alpha_t = 1 - \beta_t$ ， $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$ ，则可**直接采样**：

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

当 T 足够大时， $\bar{\alpha}_T \approx 0$ ，因此 $\mathbf{x}_T \approx \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。

扩散过程 - 任意时刻采样

重要性质：扩散过程采用**固定的 variance schedule**（如 DDPM 使用线性 schedule）

目标：从 $\mathbf{x}_0$ 直接采样任意步 $\mathbf{x}_t$ ，无需逐步计算

定义 $\alpha_t = 1 - \beta_t$ 和 $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$ 。由单步扩散的**重参数化**：

$$\mathbf{x}_t = \sqrt{\alpha_t} \mathbf{x}_{t-1} + \sqrt{1 - \alpha_t} \boldsymbol{\epsilon}_{t-1}, \quad \boldsymbol{\epsilon}_{t-1} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

递归代入 $\mathbf{x}_{t-1}$ ：

$$\begin{aligned} \mathbf{x}_t &= \sqrt{\alpha_t} \left(\sqrt{\alpha_{t-1}} \mathbf{x}_{t-2} + \sqrt{1 - \alpha_{t-1}} \boldsymbol{\epsilon}_{t-2} \right) + \sqrt{1 - \alpha_t} \boldsymbol{\epsilon}_{t-1} \\ &= \sqrt{\alpha_t \alpha_{t-1}} \mathbf{x}_{t-2} + \sqrt{\alpha_t (1 - \alpha_{t-1})} \boldsymbol{\epsilon}_{t-2} + \sqrt{1 - \alpha_t} \boldsymbol{\epsilon}_{t-1} \end{aligned}$$

由于 $\boldsymbol{\epsilon}_{t-2}$ 和 $\boldsymbol{\epsilon}_{t-1}$ **独立**，利用高斯性质合并：

$$\sqrt{\alpha_t (1 - \alpha_{t-1})} \boldsymbol{\epsilon}_{t-2} + \sqrt{1 - \alpha_t} \boldsymbol{\epsilon}_{t-1} = \sqrt{\alpha_t (1 - \alpha_{t-1}) + (1 - \alpha_t)} \bar{\boldsymbol{\epsilon}}_{t-2}$$

其中： $\alpha_t (1 - \alpha_{t-1}) + (1 - \alpha_t) = \alpha_t - \alpha_t \alpha_{t-1} + 1 - \alpha_t = 1 - \alpha_t \alpha_{t-1}$

扩散过程 - 任意时刻采样 (续)

因此:

$$\mathbf{x}_t = \sqrt{\alpha_t \alpha_{t-1}} \mathbf{x}_{t-2} + \sqrt{1 - \alpha_t \alpha_{t-1}} \bar{\epsilon}_{t-2}$$

继续递归, 依此类推:

$$\begin{aligned} \mathbf{x}_t &= \sqrt{\alpha_t \alpha_{t-1} \alpha_{t-2}} \mathbf{x}_{t-3} + \sqrt{1 - \alpha_t \alpha_{t-1} \alpha_{t-2}} \bar{\epsilon}_{t-3} \\ &= \dots \\ &= \sqrt{\prod_{i=1}^t \alpha_i} \mathbf{x}_0 + \sqrt{1 - \prod_{i=1}^t \alpha_i} \epsilon \\ &= \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \end{aligned}$$

因此得到闭式解:

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I})$$

关键: 多个独立高斯噪声的线性组合仍为高斯噪声

反向过程 - 盖楼

核心目标：扩散过程将数据**噪声化**，反向过程则是**去噪**的过程

如果我们知道反向过程每一步的真实分布 $q(\mathbf{x}_{t-1}|\mathbf{x}_t)$ ，那么从随机噪声 $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 开始，逐步去噪就能生成真实样本。

问题：估计 $q(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 需要用到整个训练样本

解决方案：用**神经网络**来估计这些分布，将反向过程定义为马尔可夫链：

$$p_{\theta}(\mathbf{x}_{0:T}) = p(\mathbf{x}_T) \prod_{t=1}^T p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t)$$

其中每一步为参数化的高斯分布：

$$p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_{\theta}(\mathbf{x}_t, t), \boldsymbol{\Sigma}_{\theta}(\mathbf{x}_t, t))$$

反向过程 - 盖楼

关键推导：利用 **贝叶斯公式** 和马尔可夫性质推导后验分布

$$q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = q(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{x}_0) \frac{q(\mathbf{x}_{t-1}|\mathbf{x}_0)}{q(\mathbf{x}_t|\mathbf{x}_0)}$$

由于马尔可夫性质： $q(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{x}_0) = q(\mathbf{x}_t|\mathbf{x}_{t-1})$

已知 $q(\mathbf{x}_{t-1}|\mathbf{x}_0) = \mathcal{N}(\sqrt{\bar{\alpha}_{t-1}}\mathbf{x}_0, (1 - \bar{\alpha}_{t-1})\mathbf{I})$ 和

$q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I})$

最终结果：后验分布仍为高斯分布

$$q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1}; \tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0), \tilde{\beta}_t\mathbf{I})$$


其中： $\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \cdot \beta_t$,

$$\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t}\mathbf{x}_0 + \frac{\sqrt{\bar{\alpha}_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}\mathbf{x}_t$$

优化目标 - VAE 视角

新视角：如果将中间产生的变量 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_{T-1}$ 看成**隐变量**

- 扩散模型是一个包含 T 个**隐变量**的隐变量模型 (Latent Variable Model)
- 可以看成是一个特殊的**层次变分自编码器** (Hierarchical VAEs)



优化目标 - 变分下界

核心问题：直接优化对数似然 $\log p_\theta(\mathbf{x}_0)$ 需要对所有隐变量 $\mathbf{x}_{1:T}$ 积分，在高维空间中**计算不可行**。

解决方案：引入**变分下界 (ELBO)** 作为可优化的替代目标。利用 Jensen 不等式：

$$\log p_\theta(\mathbf{x}_0) \geq \mathbb{E}_{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p_\theta(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right] = L_{\text{VLB}}$$

其中：

- 生成模型（反向过程）： $p_\theta(\mathbf{x}_{0:T}) = p(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$
- 前向扩散过程： $q(\mathbf{x}_{1:T}|\mathbf{x}_0) = \prod_{t=1}^T q(\mathbf{x}_t|\mathbf{x}_{t-1})$ （固定，无参数）

关键性质：

$$\log p_\theta(\mathbf{x}_0) = L_{\text{VLB}} + D_{\text{KL}}(q(\mathbf{x}_{1:T}|\mathbf{x}_0) \parallel p_\theta(\mathbf{x}_{1:T}|\mathbf{x}_0))$$

最大化 ELBO 同时实现：(1) 提升数据似然下界；(2) 使近似后验接近真实后验 $p_\theta(\mathbf{x}_{1:T}|\mathbf{x}_0)$ 。

损失函数：最小化 $L = -L_{\text{VLB}} = \mathbb{E}_{\mathbf{x}_0 \sim q(\mathbf{x}_0)} \left[\mathbb{E}_{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{q(\mathbf{x}_{1:T}|\mathbf{x}_0)}{p_\theta(\mathbf{x}_{0:T})} \right] \right]$

优化目标 - 损失函数分解

通过代数变换，负变分下界可分解为三项（外层对 $\mathbf{x}_0$ 求期望）：

$$\begin{aligned} L = \mathbb{E}_{\mathbf{x}_0 \sim q(\mathbf{x}_0)} & \left[\underbrace{D_{\text{KL}}(q(\mathbf{x}_T | \mathbf{x}_0) \parallel p(\mathbf{x}_T))}_{L_T} \right. \\ & + \underbrace{\sum_{t=2}^T \mathbb{E}_{q(\mathbf{x}_t | \mathbf{x}_0)} \left[D_{\text{KL}}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \parallel p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t)) \right]}_{L_{t-1}} \\ & \left. + \underbrace{\mathbb{E}_{q(\mathbf{x}_1 | \mathbf{x}_0)} \left[-\log p_{\theta}(\mathbf{x}_0 | \mathbf{x}_1) \right]}_{L_0} \right] \end{aligned}$$

三项含义：

- L_T ：确保 $\mathbf{x}_T$ 与先验 $p(\mathbf{x}_T) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ 一致（与 θ 无关）
- L_{t-1} ：最小化预测分布与真实后验的 KL 散度（主导训练）
- L_0 ：重构项，从 $\mathbf{x}_1$ 重建 $\mathbf{x}_0$ 的负对数似然

优化目标 - 参数化方式

关键问题：如何参数化 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) = \mathcal{N}(\boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \boldsymbol{\Sigma}_\theta(\mathbf{x}_t, t))$?

方差处理：DDPM 采用 **固定方差**。两种选择：

- $\boldsymbol{\Sigma}_\theta = \beta_t \mathbf{I}$ (前向过程方差, **实际选择**)
- $\boldsymbol{\Sigma}_\theta = \tilde{\beta}_t \mathbf{I} = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t} \beta_t \mathbf{I}$ (真实后验方差)

均值优化： $L_{t-1} = \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} \left[D_{\text{KL}}(q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \| p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)) \right]$

涉及两个高斯分布 (理论推导：假设 $\sigma_t^2 = \tilde{\beta}_t$ 以简化 KL)：

- 真实后验： $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\tilde{\boldsymbol{\mu}}_t, \tilde{\beta}_t \mathbf{I})$
- 预测分布： $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) = \mathcal{N}(\boldsymbol{\mu}_\theta, \tilde{\beta}_t \mathbf{I})$

KL 散度化简：协方差相同时：

$$D_{\text{KL}}(\mathcal{N}(\boldsymbol{\mu}_1, \tilde{\beta}_t \mathbf{I}) \| \mathcal{N}(\boldsymbol{\mu}_2, \tilde{\beta}_t \mathbf{I})) = \frac{1}{2\tilde{\beta}_t} \|\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2\|^2$$

因此：
$$L_{t-1} = \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} \left[\frac{1}{2\tilde{\beta}_t} \|\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) - \boldsymbol{\mu}_\theta(\mathbf{x}_t, t)\|^2 \right]$$

优化目标 - 噪声预测

核心技巧：将均值预测转化为**噪声预测**，简化损失函数。

回顾扩散过程：给定 $\mathbf{x}_0 \sim q(\mathbf{x}_0)$ 和 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$,

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$$

代入后验均值： $\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon \right)$

关键 **insight**：让网络**预测噪声** $\epsilon_\theta(\mathbf{x}_t, t)$ ，参数化为：

$$\mu_\theta(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(\mathbf{x}_t, t) \right)$$


代入 L_{t-1} 得理论推导的损失（若协方差为 $\tilde{\beta}_t \mathbf{I}$ ）：

$$L_{t-1} = \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} \left[\frac{\beta_t^2}{2\tilde{\beta}_t \alpha_t (1 - \bar{\alpha}_t)} \|\epsilon - \epsilon_\theta(\mathbf{x}_t, t)\|^2 \right]$$

DDPM 简化：忽略权重系数提升训练稳定性，且与方差选择无关：

$$L_{\text{simple}} = \mathbb{E}_{t \sim U(1, T)} \mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t)\|^2 \right]$$

案例展示



Thanks!